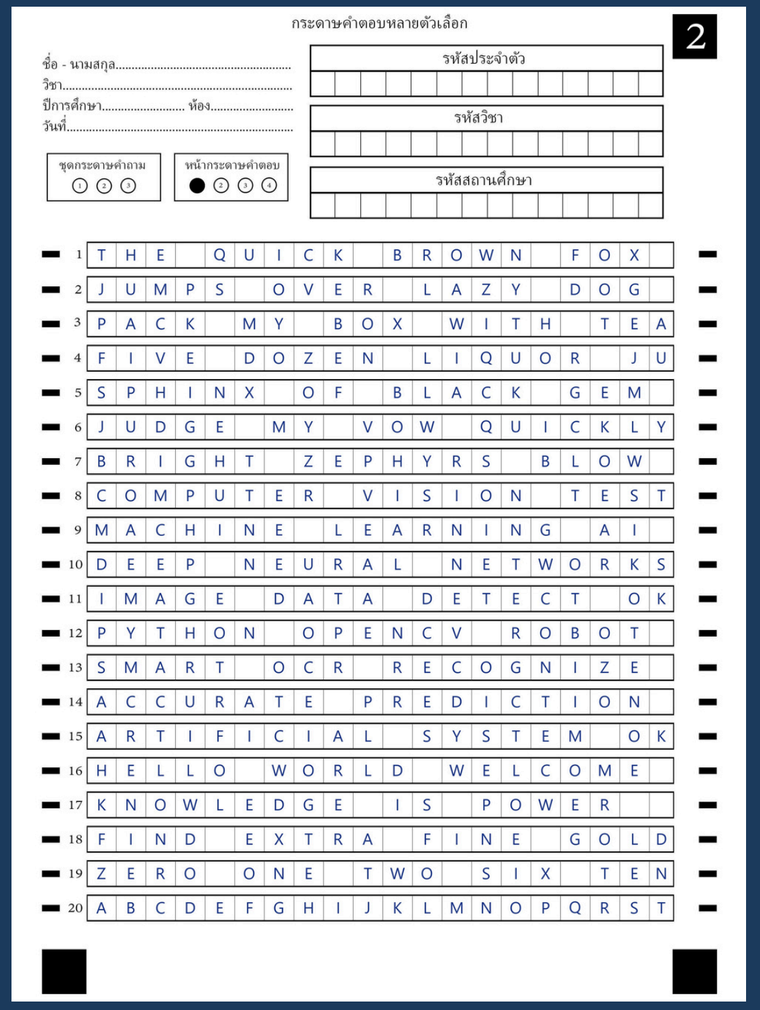
โครงงานเทคโนโลยีทางการศึกษา

ระบบตรวจกระดาษคำตอบด้วย Computer Vision (CV) และ Machine Learning (ML)

สำหรับชุดกระดาษคำตอบแบบข้อเขียนภาษาอังกฤษ

Computer Vision | Machine Learning | รู้จำลายมือ A–Z



ที่มา ความสำคัญ และวัตถุประสงค์

ที่มาและความสำคัญ

การตรวจข้อสอบด้วยคนใช้เวลา และอาจเกิดความผิดพลาดได้สูงเมื่อมีข้อสอบจำนวนมาก

ระบบ OMR ช่วยลดภาระได้ แต่มีข้อจำกัดด้านต้นทุน อุปกรณ์เฉพาะ และความยุ่งยากในการใช้งาน

โรงเรียนที่มีงบประมาณจำกัดจึงเข้าถึงเทคโนโลยีดังกล่าวได้ยาก

วัตถุประสงค์

พัฒนาระบบ CV และ ML อ่านตัวอักษรภาษาอังกฤษพิมพ์ใหญ่ A–Z และช่องว่างจากภาพกระดาษคำตอบ

ลดภาระผู้สอน เพิ่มความสม่ำเสมอในการให้คะแนน และลดความผิดพลาดของผู้ตรวจ

ใช้งานสะดวก ลดการพึ่งพาเครื่อง OMR ให้สถานศึกษาที่มีงบจำกัดเข้าถึงได้ง่ายขึ้น

ขอบเขตและเงื่อนไขการใช้งาน

20 × 20

ตรวจเฉพาะตารางคำตอบ 20 × 20 (400 ช่อง/แผ่น) (ตัดส่วนหัวกระดาษออกอัตโนมัติ ไม่ตรวจชื่อ-นามสกุล เลขนิสิต และ รหัสสถานศึกษา)

27 คลาส

ตัวอักษรอังกฤษพิมพ์ใหญ่ A–Z และช่องว่าง

เครื่องมือเขียน

ปากกาหมึกซึม ปากกาลูกลื่น ปากกาเจล และดินสอไส้บาง

ภาพถ่าย

เห็นกรอบตารางคำตอบ 20 × 20 ครบทั้ง 4 มุม ชัดเจน (แม้แถบมาร์กเกอร์ด้านข้างถูกนิ้วบังก็ยังตรวจได้)

การเขียน

หนึ่งตัวอักษรต่อช่อง ไม่ล้ำช่องข้างเคียงมาก และใช้เฉลยตรงกับเทมเพลต

การตรวจทานโดยมนุษย์

ช่องความมั่นใจต่ำถูกแท็ก Needs_Review ระบบเป็นเครื่องมือช่วย ไม่ใช่ผู้ตัดสินขั้นสุดท้าย

ข้อมูลที่ใช้และข้อจำกัดของระบบ

87 ภาพ
ชุดฝึกสอนภาพถ่ายกระดาษ ใช้ร่วมกับข้อมูล EMNIST / KAGGLE A–Z

52,201 ช่อง
ข้อมูลฝึกสอนรวม ขยายด้วย Data Augmentation กว่า 420,000 รูปแบบ

12 แผ่น · 4,800 ช่อง
ชุดทดสอบจริง (12 × 400 ช่อง)

สภาพแวดล้อม **Python 3.10+, OpenCV, Scikit-learn, PyTorch รองรับ GPU Acceleration (CUDA) และ CPU Fallback**

สิ่งที่ไม่รองรับ

- ตัวพิมพ์เล็ก ตัวเลข อักขระพิเศษ และอักษรภาษาไทย
- ข้อมูลส่วนหัวกระดาษคำตอบ (ชื่อ-นามสกุล, รหัสนิสิต / เลขประจำตัว, รหัสวิชา, รหัสสถานศึกษา และช่องฝนปรนัยด้านบน)
- ตารางขนาดอื่นที่ไม่ใช่ 20 × 20 หรือแบบฟอร์มที่ไม่มีเส้นกรอบตารางชัดเจน
- ภาพเอียงรุนแรง เบลอมาก หรือภาพที่แสงเงาเข้มจัด
- การแก้คำสะกดอัตโนมัติ (เช่น FIND ไม่ถูกแก้เป็น FINE)
- การทำงานแบบเรียลไทม์บนมือถือ และเว็บแอปพลิเคชัน

ขั้นตอนการทำงานของระบบ 8 ขั้นตอน

การประมวลผลภาพ

1
Universal Grid Refinement & Warp
ล็อกขอบตาราง และปรับระนาบและแก้ความเอียงของภาพ

2
Dynamic Profiling
ตรวจหาเส้นตารางและแบ่ง 20 × 20 ช่องแบบไดนามิก

3
Variance Gate
คัดกรองช่องว่าง

4
Centroid Alignment
จัดตัวอักษรให้อยู่กึ่งกลาง

โมเดล AI และการแก้ผลลัพธ์

5
Dual-Stream AI
วิเคราะห์ด้วย Dual-MLP และ CharCNN

6
Super-Ensemble
รวมผล MLP และ CNN

7
Topological Disambiguation
ใช้กฎโครงสร้างแยกตัวอักษรที่คล้ายกัน

8
Academic Integrity
แสดงตามตัวอักษรที่เขียนจริง ไม่ปรับแต่งคำด้วย NLP

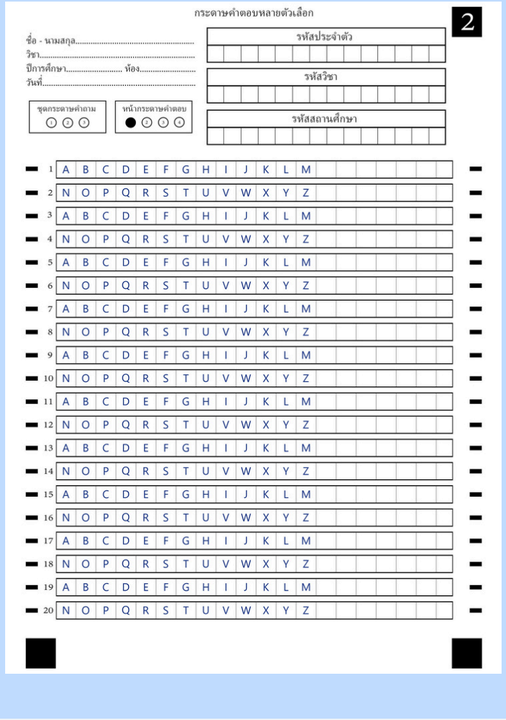
การเตรียมชุดข้อมูลฝึกสอนและชุดทดสอบจริง

Train

56,854 ช่อง

(87แผ่น + EMNIST & Kaggle A–Z)

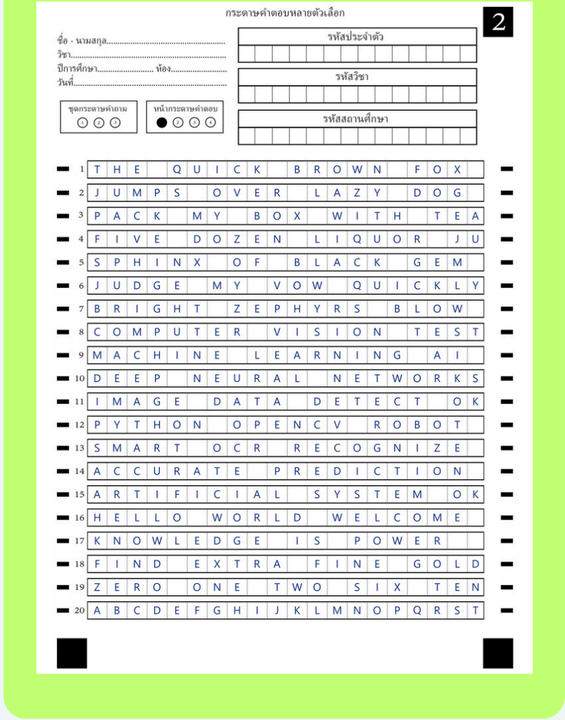
ขยายด้วย Data Augmentation กว่า 470,000 รูปแบบ



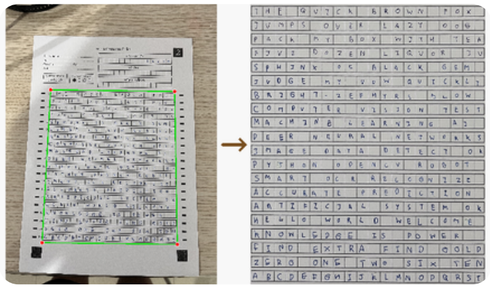
Test

12 แผ่น

4,800 ช่อง



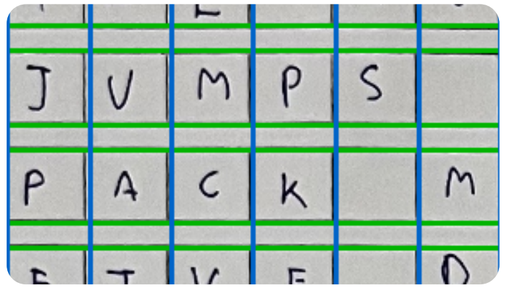
การประมวลผลภาพและการเตรียมคุณลักษณะ



ขั้นที่ 1

Homography Matrix

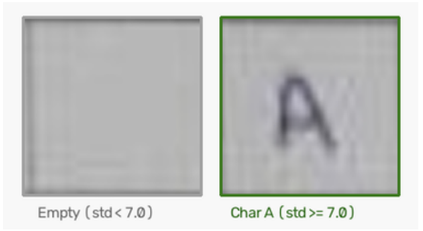
ปรับภาพกระดาษให้เป็นระนาบมาตรฐาน



ขั้นที่ 2

Vertical Projection Profiling

แบ่งตาราง 20 × 20 ลด Grid Drift (แก้ความคลาดเคลื่อนได้ 10–12 พิกเซล)

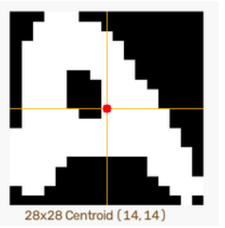


ช่องว่าง มีตัวอักษร

ขั้นที่ 3

Variance / Contrast Gate

คัดช่องว่างเมื่อ std < 7.0 หรือ diff < 35 โดยไม่ส่งเข้าโมเดล AI



(14, 14)

ขั้นที่ 4

Image Moments

จัดจุดศูนย์กลางของตัวอักษรให้อยู่ที่ (14, 14)

สกัดคุณลักษณะรวม

1,176 มิติ

เทนเซอร์ภาพ 2 มิติ

1 × 28 × 28

พิกเซล 784 มิติ	HOG 392 มิติ	สำหรับ Dual-Ensemble MLP
2D Grayscale Tensor (28×28)		สำหรับ Custom 2D CNN

การแยกแยะตัวอักษรที่รูปทรงคล้ายกัน

กฎโครงสร้างแยกตัวอักษรที่คล้ายกัน

B / R

ตรวจโครงสร้างขาช่วงล่าง
ระยะห่างขาคู่ล่าง max_gap ≥ 9 px (R) · ขาโค้งปิด (B)

C / O

ตรวจการปิดวงกลม
Morphological Loop ปิดสนิท (O) · มีช่องเปิดฝั่งขวา (C)

F / E

ตรวจระยะเอื้อมของแขนล่าง
ความยาวขีดล่างเทียบขีดบน ≥ 70% (E) · ไม่มีขีดล่าง (F)

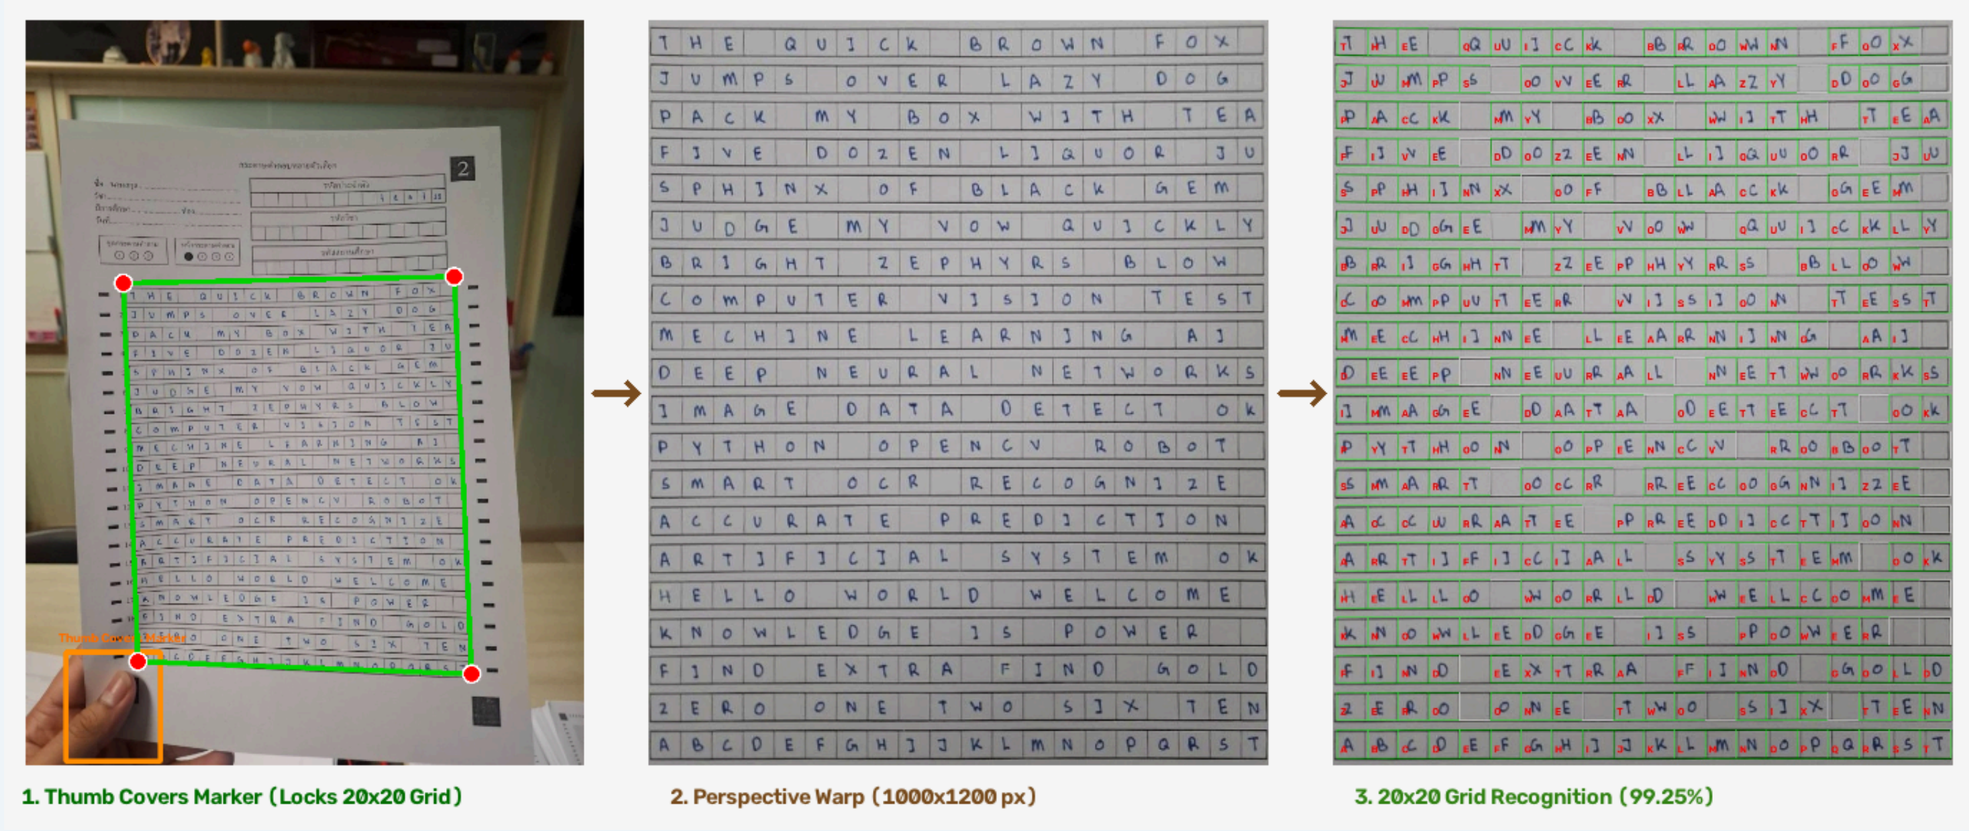
U / V

แยกจากปลายแหลมและความโค้งมน
ปลายแหลม ≤ 3px (V) · โค้งมน ≥ 40% (U)

C / D

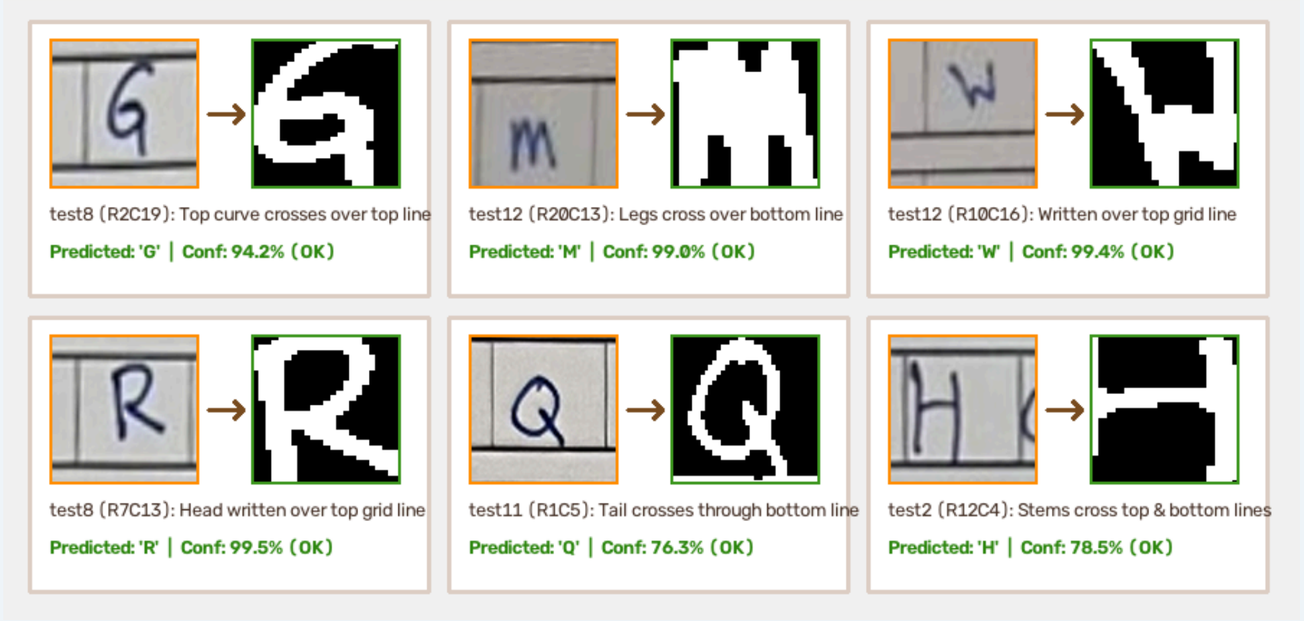
ตรวจโครงสร้างเส้นสันหลัง
ความตรงของเส้นตั้งฝั่งซ้าย spine ≥ 85% (D) · โค้งมน (C)

จุดเด่นที่ 1: ระบบตรวจจับขอบตารางโดยตรง แม้แถบมาร์กเกอร์ถูกบัง หรือ ขาดหาย (Marker-Independent Grid Locking)



ระบบทั่วไปจะตรวจไม่ได้ทันทีหากมาร์กเกอร์ 4 มุมถูกนิ้วบังหรือขาดหาย แต่ระบบของเราตรวจจับโครงสร้างเส้นกรอบตาราง 20×20 โดยตรง ทำให้ตัดส่วนหัวกระดาษ ปรับระนาบภาพถือถ่าย และอ่านคำตอบในแผ่น testได้แม่นยำถึง 99.25% (397 / 400 ช่อง)

จุดเด่นที่ 2: ความทนทานต่อลายมือเขียนชิดขอบหรือทับเส้นตาราง (Overlapping Border Recovery)



ปัญหาที่พบบ่อยในการสอบจริง

ผู้เข้าสอบมักเขียนตัวอักษรชิดขอบ ลากหางยาวทะลุเส้นตาราง (เช่น G, M, Q, R) หรือมีเส้นจากช่องข้างเคียงล้ำเข้ามา (เช่น H) ซึ่งทำให้ OCR ทั่วไปอ่านผิดพลาด

การสกัดเฉพาะเนื้อตัวอักษร

ระบบตัดขอบใน (pad_x=5, pad_y=4) ร่วมกับการกรอง Connected Components เพื่อลบเส้นตารางออก เหลือเฉพาะเส้นหมึกของตัวอักษรแล้วจัดกึ่งกลาง 28×28 px

ความทนทานของโมเดล

ผสาน Focal Loss (Lin, 2017) และ Random Stroke Erasing (Zhong, 2020) ช่วยให้โมเดลจำแนกตัวอักษรที่เขียนทับเส้นได้ถูกต้องแม่นยำทุกรูปแบบ

ผลการทดลองรายแผ่น (Per-Sheet Accuracy Breakdown)

ทดสอบกับกระดาษคำตอบจริง 12 แผ่น (แผ่นละ 20 ข้อ × 20 ช่อง = 400 ช่อง · รวมทั้งหมด 4,800 ช่อง)

PER-SHEET ACCURACY BREAKDOWN : 27 Classes: A-Z & Blank)

Test Sheet	Dual-Ensemble MLP	Custom 2D CNN	Super-Ensemble
test1.jpg	398/400 (99.50%)	395/400 (98.75%)	397/400 (99.25%)
test2.jpg	311/400 (77.75%)	336/400 (84.00%)	335/400 (83.75%)
test3.jpg	381/400 (95.25%)	383/400 (95.75%)	385/400 (96.25%)
test4.jpg	397/400 (99.25%)	398/400 (99.50%)	398/400 (99.50%)
test5.jpg	373/400 (93.25%)	373/400 (93.25%)	375/400 (93.75%)
test6.jpg	379/400 (94.75%)	389/400 (97.25%)	388/400 (97.00%)
test7.jpg	389/400 (97.25%)	389/400 (97.25%)	390/400 (97.50%)
test8.jpg	376/400 (94.00%)	377/400 (94.25%)	381/400 (95.25%)
test9.jpg	358/400 (89.50%)	374/400 (93.50%)	376/400 (94.00%)
test10.jpg	329/400 (82.25%)	358/400 (89.50%)	353/400 (88.25%)
test11.jpg	381/400 (95.25%)	393/400 (98.25%)	391/400 (97.75%)
test12.jpg	394/400 (98.50%)	397/400 (99.25%)	397/400 (99.25%)

วิเคราะห์ผลการทดลองรายแผ่น :
โมเดล Super-Ensemble ชนะหรือเทียบเท่าโมเดลเดี่ยวในเกือบทุกแผ่นทดสอบ โดยเฉพาะในแผ่นที่ยากที่สุดอย่าง test2.jpg และ test10.jpg (เขียนทับเส้นตาราง) ที่ความแม่นยำก้าวกระโดดขึ้นกว่า +6.00% เมื่อเทียบกับ MLP แบบดั้งเดิม และทำได้สูงถึง 99.25% (397/400 ช่อง) ในแผ่น test12.jpg ที่ถือถ่ายโดยนิ้วบังมาร์กเกอร์มุมกระดาษ

สรุปเปรียบเทียบโมเดล 3 แบบ และ ตารางประเมินผล

โมเดล 3 แบบ

Dual-Ensemble MLP

สกัดคุณลักษณะเชิงเส้นและโครงสร้างจากภาพ 28×28

93.04%

Custom 2D CNN

CharCNN + Focal Loss (γ = 2.0) ร่วมกับ Random Stroke Erasing

95.04%

Super-Ensemble

ถ่วงน้ำหนักความน่าจะเป็น MLP + CNN

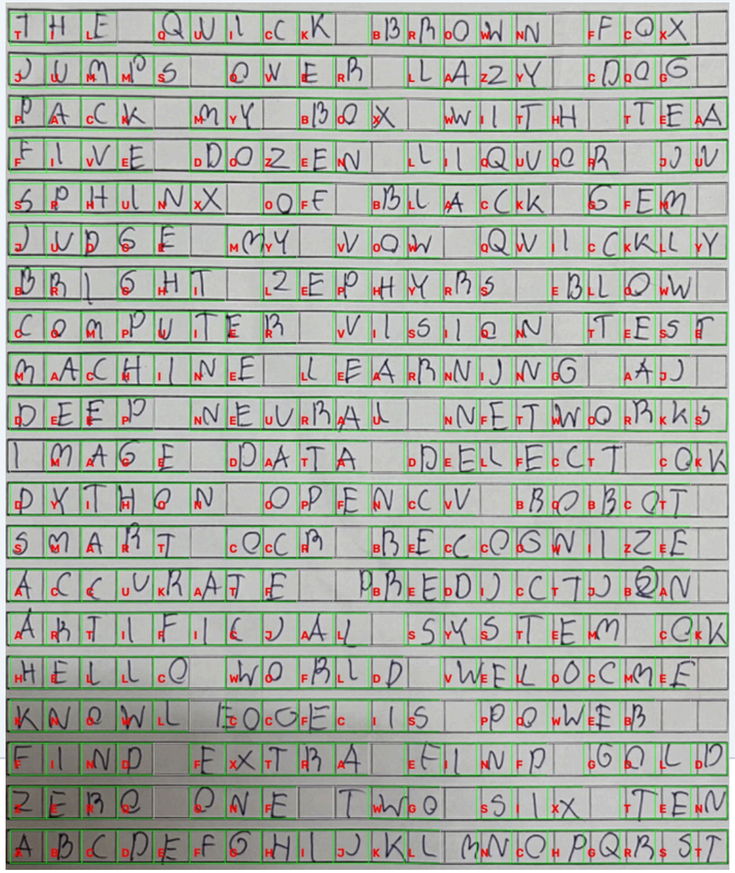
95.12%

Super-Ensemble ถ่วงดุลความเสี่ยงระหว่างฟีเจอร์ขอบเส้น (MLP) และโครงสร้าง 2 มิติ (CNN) ช่วยลดอัตราความผิดพลาดรวมลงถึง 29.9% และได้ค่า F1-Score สูงสุดที่ 94.44%

ตารางประเมินผล

```
MAIN MODEL EVALUATION BENCHMARK
Referenced Papers:
  - Accuracy (CRA) & Error Rate (CER) : Cohen et al. (IEEE IJCNN 2017) - EMNIST Benchmark
  - Precision, Recall & F1-Score      : Oqaibi et al. (IEEE ICECCME 2021) - Multi-Class HCR Evaluation
  - 2D CNN Architecture & Training    : Lin et al. (IEEE ICCV 2017, Focal Loss) & Zhong et al. (AAAI 2020, Random Erasing)
=================================================================================================================
Model Architecture                      | Correct (4,800) |  Accuracy   |  Error Rate  |  Precision   |   Recall    |  F1-Score
(Evaluated on 27 Classes: A-Z & -)      |      Cells      | (Cohen 17)  | (Cohen 17)   | (Oqaibi 21)  | (Oqaibi 21) | (Oqaibi 21)
-----------------------------------------------------------------------------------------------------------------
1. Dual-Ensemble MLP (HOG + Pixel)      |  4,466 / 4,800  |     93.04%  |       6.96%  |     90.51%   |    92.89%   |    91.51%
2. Custom 2D CNN (Lin 2017 + Zhong 2020)|  4,562 / 4,800  |     95.04%  |       4.96%  |     93.69%   |    95.22%   |    94.35%
3. Super-Ensemble (MLP + CNN)           |  4,566 / 4,800  |     95.12%  |       4.88%  |     93.70%   |    95.36%   |    94.44%
-----------------------------------------------------------------------------------------------------------------
```

กรณีศึกษาเคสยาก



ผลการทดสอบที่มีการเพิ่มขึ้นมากที่สุด

+6.00%

ตรวจตัวอักษรถูกเพิ่มขึ้น +24 อักขระสำเร็จ

ตอนที่ใช้ Dual-Ensemble MLP

77.75% (311 / 400 ช่อง)

ตอนที่ใช้ Custom 2D CNN (CharCNN + Focal)

84.00% (336 / 400 ช่อง)

ตอนที่ใช้ Super-Ensemble (30% MLP + 70% CNN)

83.75% (335 / 400 ช่อง)

ปัญหาที่พบ : เส้นขาดช่วง และ เขียนหวัดทับเส้นตาราง

- การแก้ด้วย CV : ใช้ Dynamic Dilation เพิ่มความหนาและเชื่อมรอยเส้นดินสอที่จางให้คมชัดขึ้น
- การแก้ด้วยโมเดล : โมเดล CNN ฝึกด้วย Focal Loss + Random Erasing จึงอ่านเส้นที่จางและขาดได้แม่นยำขึ้น +24 ตัวอักษร

ประโยชน์ ข้อจำกัด และแนวทางพัฒนาต่อ

ประโยชน์ที่ได้รับ

ลดเวลาอ่านและบันทึกคำตอบ 400 ช่องต่อแผ่น รองรับการประมวลผลหลายแผ่น

ใช้ภาพจากสมาร์ตโฟนทั่วไป ไม่ต้องใช้เครื่องสแกนเฉพาะทาง

ส่งออก JSON ภาพตีกรอบผลการอ่าน และ Excel Dashboard สรุปรายแผ่นและรายช่อง

ระบุค่า Confidence รายช่อง พร้อมคัดกรองสถานะ Needs Review อัตโนมัติ ช่วยลดภาระผู้ตรวจไม่ต้องตรวจเช็กทุกช่อง

ข้อจำกัดที่พบ

- ลายมือปากกาที่เส้นจางมากยังแม่นยำต่ำกว่า (แม้ Super-Ensemble จะช่วยดึงขึ้นมาได้ถึง 83.75% หรือ 335/400 ช่อง ใน test2.jpg แต่ยังต่ำกว่าแผ่นปากกาทั่วไปที่ทำได้ >95%)
- การรวมพลัง (Super-Ensemble) แบบถ่วงน้ำหนักคงที่ (Fixed Weight 30:70) อาจถูกโมเดลคู่ดึงคะแนนลงเล็กน้อยในบางแผ่น

แนวทางพัฒนาต่อ

- พัฒนาระบบ Dynamic / Confidence-based Model Routing
- ขยาย Data Augmentation สำหรับปากกาที่จาง และ แสงเงา

สรุปและงานวิจัยที่เกี่ยวข้อง

สรุปผลโครงการ

ครบทั้งกระบวนการ

ตั้งแต่รับภาพถ่ายมุมกว้างจากสมาร์ตโฟน, ปรับระนาบอัตโนมัติ (Universal Table Refinement), จำแนกตัวอักษรด้วย Dual-Stream (MLP + CNN), จนถึงส่งออก JSON และ Excel Dashboard สรุปผลพร้อมภาพตีกรอบ

ความแม่นยำรวม 95.12%

CV ร่วมกับ MLP/CNN (Super-Ensemble) อ่านถูก 4,566 จาก 4,800 ช่อง

สิ่งที่ต้องพัฒนาต่อ

พัฒนา Dynamic Routing: สลับเลือกโมเดลอัตโนมัติตามระดับความมั่นใจรายช่อง

งานวิจัยที่เกี่ยวข้อง

2017 — Cohen et al. (IEEE IJCNN 2017)
EMNIST: Extending MNIST to Handwritten Letters (IEEE IJCNN)

2017 — Lin et al. (IEEE ICCV 2017)
Focal Loss for Dense Object Detection

2020 — Zhong et al. (AAAI 2020) & Oqaibi et al. (IEEE 2021)
Random Erasing Data Augmentation

2021 — Oqaibi et al. (IEEE ICECCME, 2021)
Handprinted Character and Online Signature Recognition Using Residual Convolutional Network: A Comparative Study