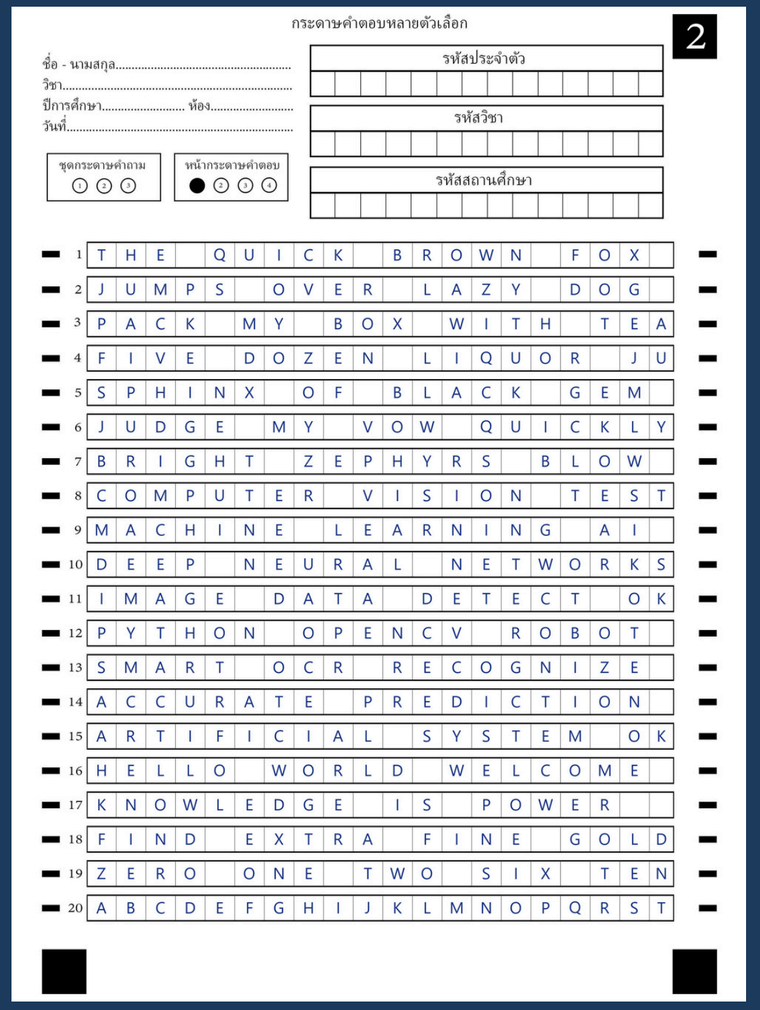
โครงงานเทคโนโลยีทางการศึกษา

ระบบตรวจกระดาษคำตอบด้วย Computer Vision (CV) และ Machine Learning (ML)

สำหรับชุดกระดาษคำตอบแบบข้อเขียนภาษาอังกฤษ

Computer Vision | Machine Learning | รู้จำลายมือ A–Z



ที่มา ความสำคัญ และวัตถุประสงค์

ที่มาและความสำคัญ

การตรวจข้อสอบด้วยคนใช้เวลา และอาจเกิดความผิดพลาดได้สูงเมื่อมีข้อสอบจำนวนมาก

ระบบ OMR ช่วยลดภาระได้ แต่มีข้อจำกัดด้านต้นทุน อุปกรณ์เฉพาะ และความยุ่งยากในการใช้งาน

โรงเรียนที่มีงบประมาณจำกัดจึงเข้าถึงเทคโนโลยีดังกล่าวได้ยาก

วัตถุประสงค์

พัฒนาระบบ CV และ ML อ่านตัวอักษรภาษาอังกฤษพิมพ์ใหญ่ A–Z และช่องว่างจากภาพกระดาษคำตอบ

ลดภาระผู้สอน เพิ่มความสม่ำเสมอในการให้คะแนน และลดความผิดพลาดของผู้ตรวจ

ใช้งานสะดวก ลดการพึ่งพาเครื่อง OMR ให้สถานศึกษาที่มีงบจำกัดเข้าถึงได้ง่ายขึ้น

ขอบเขตและเงื่อนไขการใช้งาน

20 × 20
= 400 ช่องต่อแผ่น
ถ่ายด้วยสมาร์ตโฟนทั่วไป

27 คลาส
ตัวอักษรอังกฤษพิมพ์ใหญ่
A–Z และช่องว่าง

เครื่องมือเขียน

ปากกาหมึกซึม ปากกาลูกลื่น ปากกาเจล และดินสอไส้บาง

ภาพถ่าย

เห็นกระดาษทั้งแผ่น ตารางและมาร์กเกอร์ชัดเจน ความละเอียดและโฟกัสเพียงพอ

การเขียน

หนึ่งตัวอักษรต่อช่อง ไม่ล้ำช่องข้างเคียงมาก และใช้เฉลยตรงกับเทมเพลต

การตรวจทานโดยมนุษย์

ช่องความมั่นใจต่ำถูกแท็ก Needs_Review ระบบเป็นเครื่องมือช่วย ไม่ใช่ผู้ตัดสินขั้นสุดท้าย

ข้อมูลที่ใช้และข้อจำกัดของระบบ

78 ภาพ
ชุดฝึกสอนภาพถ่ายกระดาษ ใช้ร่วมกับข้อมูล EMNIST / Kaggle A–Z

52,201 ช่อง
ข้อมูลฝึกสอนรวม ขยายด้วย Data Augmentation กว่า 420,000 รูปแบบ

9 แผ่น · 3,600 ช่อง
ชุดทดสอบจริง (9 × 400 ช่อง)

สภาพแวดล้อม Python 3.10+, OpenCV, Scikit-learn บนคอมพิวเตอร์ทั่วไป ไม่ต้องใช้ GPU

สิ่งที่ไม่รองรับ

- ตัวพิมพ์เล็ก ตัวเลข อักขระพิเศษ และอักษรภาษาไทย
- ตารางขนาดอื่น หรือแบบฟอร์มที่ไม่มีกรอบและมาร์กเกอร์ชัดเจน
- ภาพเอียงรุนแรง เบลอมาก ถูกบังบางส่วน หรือแสงเงาเข้มจัด
- การแก้คำสะกดอัตโนมัติ (เช่น FIND ไม่ถูกแก้เป็น FINE)
- การทำงานแบบเรียลไทม์บนมือถือ และเว็บแอปพลิเคชัน

ขั้นตอนการทำงานของระบบ 8 ขั้นตอน

การประมวลผลภาพ

1
Perspective Warp

ปรับระนาบและแก้ความเอียงของภาพ

2
Dynamic Profiling

ตรวจหาเส้นตารางและแบ่ง 20 × 20 ช่องแบบไดนามิก

3
Variance Gate

คัดกรองช่องว่าง

4
Centroid Alignment

จัดตัวอักษรให้อยู่กึ่งกลาง

โมเดล AI และการแก้ผลลัพธ์

5
Dual-Stream AI

วิเคราะห์ด้วย Dual-MLP และ CharCNN

6
Super-Ensemble

รวมผล MLP 30% และ CNN 70%

7
Topological Disambiguation

ใช้กฎโครงสร้างแยกตัวอักษรที่คล้ายกัน

8
Academic Integrity

แสดงตามตัวอักษรที่เขียนจริง ไม่ปรับแต่งคำด้วย NLP

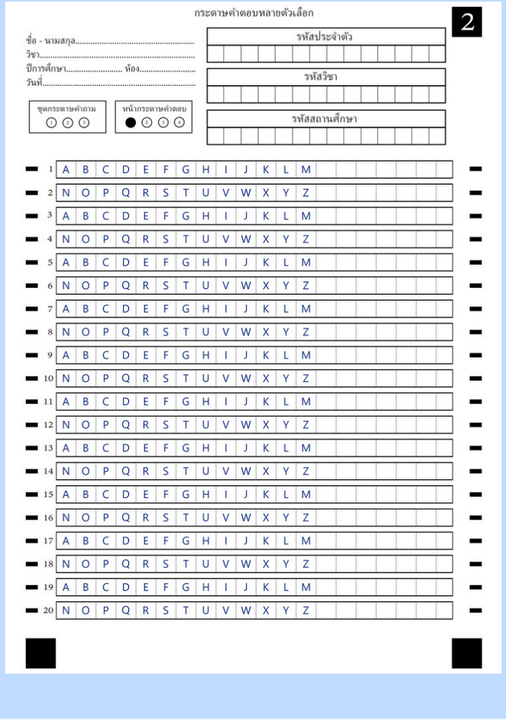
การเตรียมชุดข้อมูลฝึกสอนและชุดทดสอบจริง

Train

52,201 ช่อง

(78 แผ่น + EMNIST & Kaggle A–Z)

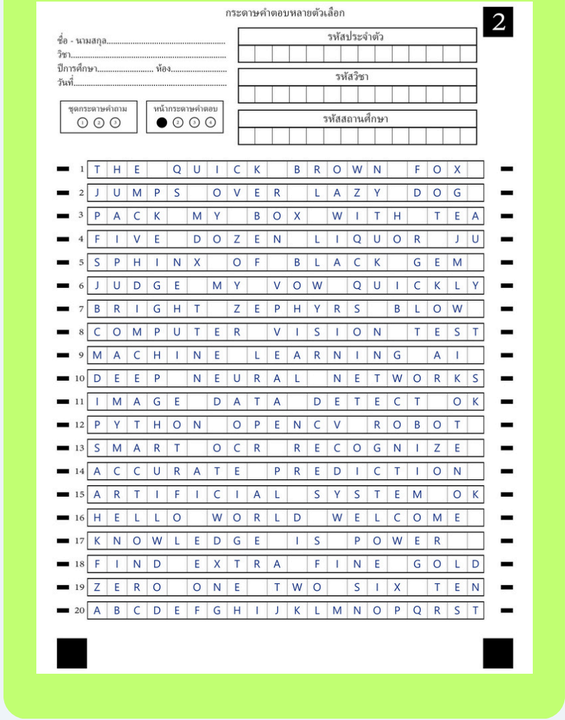
ขยายด้วย Data Augmentation กว่า 420,000 รูปแบบ



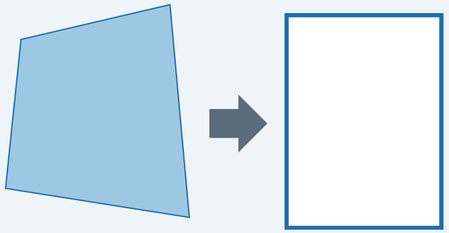
Test

9 แผ่น

3600 ช่อง



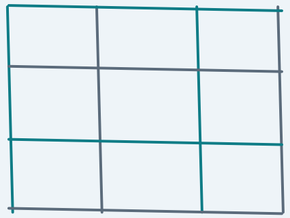
การประมวลผลภาพและการเตรียมคุณลักษณะ



ขั้นที่ 1

Homography Matrix

ปรับภาพกระดาษให้เป็นระนาบมาตรฐาน



ขั้นที่ 2

Vertical Projection Profiling

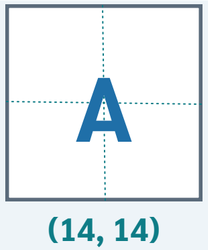
แบ่งตาราง 20 × 20 ลด Grid Drift (เอกสารระบุว่าแก้ความคลาดเคลื่อนได้ 10–12 พิกเซล)



ขั้นที่ 3

Variance / Contrast Gate

คัดช่องว่างเมื่อ std < 7.0 หรือ diff < 35 โดยไม่ส่งเข้าโมเดล AI



ขั้นที่ 4

Image Moments

จัดจุดศูนย์กลางของตัวอักษรให้อยู่ที่ (14, 14)

สกัดคุณลักษณะรวม

1,176 มิติ

พิกเซล 784 มิติ | HOG 392 มิติ

โมเดล AI และกฎแก้ความสับสน

โมเดล 3 แบบ (ความแม่นยำรวม 9 แผ่น · 3,600 ช่อง)

Dual-Ensemble MLP

สกัดคุณลักษณะเชิงเส้นและโครงสร้างจากภาพ 28×28

93.94%

Custom 2D CNN

CharCNN + Focal Loss (γ = 2.0) ร่วมกับ Random Stroke Erasing

93.67%

Super-Ensemble

ถ่วงน้ำหนักความน่าจะเป็น MLP 30% + CNN 70%

94.03%

Super-Ensemble ใช้การถ่วงน้ำหนักความน่าจะเป็น ไม่ได้รับประกันว่าจะดีที่สุดในทุกแผ่นทดสอบ

กฎโครงสร้างแยกตัวอักษรที่คล้ายกัน

B / R — **ตรวจโครงสร้างขาช่วงล่าง**

max_gap ≥ 9

F / E — **ตรวจระยะเอื้อมของแขนล่าง**

reach ≥ 70%

C / D — **ตรวจโครงสร้างเส้นสันหลัง**

spine ≥ 85%

C / O — **ตรวจการปิดวงกลม**

Morphological Loop

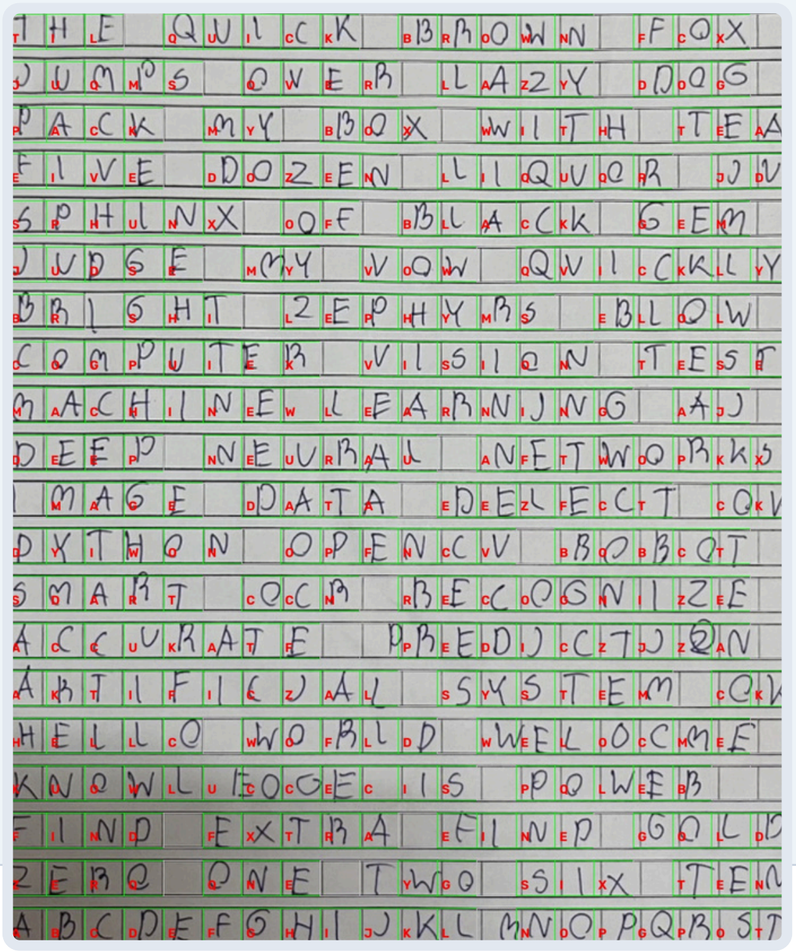
U / V — **แยกจากปลายแหลมและความโค้งมน**

ปลายแหลม ≤ 3px (V) · โค้งมน ≥ 40% (U)

ผลการทดลอง

แผ่นทดสอบ	1. Dual-Ensemble	2. Custom 2D CNN	3. Super-Ensemble	ผลต่างเทียบเดิม	Super Conf
test1.jpg	99.75% (399/400)	97.50% (390/400)	98.00% (392/400)	-1.75% (-7 ตัว)	96.81%
test2.jpg	80.75% (323/400)	82.00% (328/400)	83.50% (334/400)	+2.75% (+11 ตัว)	86.86%
test3.jpg	95.25% (381/400)	95.75% (383/400)	95.50% (382/400)	+0.25% (+1 ตัว)	94.55%
test4.jpg	99.25% (397/400)	97.50% (390/400)	97.75% (391/400)	-1.50% (-6 ตัว)	96.95%
test5.jpg	93.50% (374/400)	94.00% (376/400)	94.50% (378/400)	+1.00% (+4 ตัว)	94.66%
test6.jpg	94.25% (377/400)	95.50% (382/400)	95.25% (381/400)	+1.00% (+4 ตัว)	95.73%
test7.jpg	97.25% (389/400)	95.00% (380/400)	95.75% (383/400)	-1.50% (-6 ตัว)	96.55%
test8.jpg	93.00% (372/400)	93.25% (373/400)	93.75% (375/400)	+0.75% (+3 ตัว)	92.54%
test9.jpg	92.50% (370/400)	92.50% (370/400)	92.25% (369/400)	-0.25% (-1 ตัว)	96.73%
รวม 9 แผ่น	93.94% (3382/3600)	93.67% (3372/3600)	94.03% (3385/3600)	+0.08% (+3 ตัว)	94.60%

โมเดลการทดสอบ (Model Variant)	จำนวนช่องที่ถูกต้อง	จำนวนช่องทั้งหมด	ความแม่นยำ (%)
Baseline Dual-Ensemble MLP	3,382	3,600	**93.94%**
Custom 2D CNN (CharCNN + Focal)	3,372	3,600	**93.67%**
Super-Ensemble (30% MLP + 70% CNN)	**3,385**	**3,600**	**94.03%**



ผลการทดสอบที่มีการเพิ่มขึ้นมากที่สุด

+2.75%

ตรวจตัวอักการถูกเพิ่มขึ้น +11 อักขระสำเร็จ

ตอนที่ใช้ Dual-Ensemble MLP

80.75% (323 / 400 ช่อง)

ตอนที่ใช้ Custom 2D CNN (CharCNN + Focal)

82.00% (328 / 400 ช่อง)

ตอนที่ใช้ Super-Ensemble (30% MLP + 70% CNN)

83.45% (334 / 400 ช่อง)

ประโยชน์ ข้อจำกัด และแนวทางพัฒนาต่อ

ประโยชน์ที่ได้รับ

ลดเวลาอ่านและบันทึกคำตอบ 400 ช่องต่อแผ่น รองรับการประมวลผลหลายแผ่น

ใช้ภาพจากสมาร์ตโฟนทั่วไป ไม่ต้องใช้เครื่องสแกนเฉพาะทาง

ส่งออก JSON ภาพตีกรอบผลการอ่าน และ Excel Dashboard สรุปรายแผ่นและรายช่อง

ค่า Confidence รายช่อง ช่วยระบุช่องน่าสงสัยเพื่อตรวจสอบย้อนกลับ

ข้อจำกัดที่พบ

- ลายมือดินสอที่เส้นจางหรือขาดยังแม่นยำน้อยกว่ากรณีทั่วไป (test2.jpg ถูก 334/400 ช่อง)
- Super-Ensemble ไม่ได้ดีกว่าโมเดลเดี่ยวทุกแผ่น (เช่น test1.jpg: 392/400 เทียบ MLP 399/400)

แนวทางพัฒนาต่อ

เพิ่มข้อมูลฝึกสอนและทำ Data Augmentation เพื่อยกระดับความแม่นยำกับลายมือดินสอเส้นจาง ให้ใกล้เคียงกับการเขียนด้วยปากกา

สรุปและงานวิจัยที่เกี่ยวข้อง

สรุปผลโครงการ

ครบทั้งกระบวนการ

ตั้งแต่รับภาพกระดาษคำตอบจนส่งออก JSON ภาพตีกรอบ และ Excel Dashboard

ความแม่นยำรวม 94.03%

CV ร่วมกับ MLP/CNN (Super-Ensemble) อ่านถูก 3,385 จาก 3,600 ช่อง

ยังต้องพัฒนาต่อ

เพิ่มความแข็งแรงต่อรูปแบบลายมือ และตรวจทานช่องที่ความมั่นใจต่ำ

งานวิจัยที่เกี่ยวข้อง

1998 — **LeCun et al.**
Gradient-Based Learning Applied to Document Recognition

2005 — **Dalal & Triggs**
Histograms of Oriented Gradients for Human Detection

2008 — **Graves et al.**
Offline Handwriting Recognition with Multidimensional RNNs

2016 — **Shi et al.**
An End-to-End Neural Network for Image-based Sequence Recognition



NOTE

เก่งมากงับเตง



เหลือสรุปหน้า 14 -20



เสร้จแล้วพร้อมพรี

แทรกเนื้อหาในสไลด์ได้เลย

อยากเปลี่ยนหน้า 9-10 เป็น 19-20

เปลี่ยนได้เลย

ถ้าเสร็จแล้วติ๊กถูก

อุณเทอเก่งที่สุด

สำคัญ



อยากให้เพิ่มตรง
หน้า 14 และ 20

ถ้าเสร็จแล้วติ๊กถูก